계획기는 결정적 오차를 이용한다: 저비트 월드모델을 위한 dither

Planners Exploit Deterministic Error: Dithered Low-Bit World Models

송용휘[1] and 이건명[2]

[1] 충북대학교 정보통신공학부, 대한민국, thddydgnl1937@gmail.com
[2] 충북대학교 소프트웨어학부, 대한민국, kmlee@cbnu.ac.kr

요약

MPPI와 CEM 같은 표본 기반 계획기는 결정 한 번에 월드모델을 수천 번 호출한다. 그런데 저비트 월드모델이 계획에서 실패하는 정도는 비트 수나 1-step 예측 오차로 설명되지 않는다. 본 연구는 손상을 정하는 것이 반올림 오차의 크기가 아니라 구조임을 보인다. 결정적 반올림(round-to-nearest)은 최적화 반복 내내 그대로 남는 오차장을 만들고, 기전을 검정한 네 과제에서 반복형 계획기는 이 오차장이 우연히 유리하게 평가하는 후보 쪽으로 이동했다. 같은 비트 수에서 학습 없이 반올림만 dither(확률적 반올림)로 바꾸고, 그 잡음을 모든 후보가 공유하며 계획기 반복마다 새로 뽑으면 이 이동의 대부분이 사라진다. TD-MPC2(MPPI, 12과제)와 DINO-WM(CEM, 3과제)으로 내부 사전등록한 실험에서 결정적 반올림은 성공률을 최대 100퍼센트포인트 떨어뜨렸지만, 손상이 실재한 36칸 중 29칸에서 그 1-step 오차는 dither보다 크지 않았다. dither는 Meta-World 손상 칸 19개 모두에서 손상의 절반 이상(중앙값 95퍼센트)을, DINO-WM 5칸 중 4칸에서 절반 이상을 없앴고, TD-MPC2의 융합 정수 kernel에서 추가 지연의 중앙값은 10퍼센트 미만이었다. 이 처방은 반복하는 계획기가 필요하고, 유리한 오차가 반복 사이에 덜 지속되는 DMC 같은 과제에서는 효과가 작다.

Keywords— 월드모델, 모델 예측 제어, 양자화, 확률적 반올림, 로봇 계획

A. 문제 설정

MPC 계획기는 결정 한 번에 월드모델을 후보 수 × 반복 수 × horizon만큼 호출한다. TD-MPC2 [1]의 MPPI는 $512\times6\times3$번, PushT에서 DINO-WM [2]의 CEM은 $300\times30\times5$번이다. 저비트 추론은 이 비용을 줄이는 가장 직접적인 방법이지만, 양자화한 월드모델은 비트 수나 오프라인 오차로 설명되지 않는 방식으로 계획을 망가뜨린다 [3, 4]. 본 연구는 MLP 은닉 활성(TD-MPC2의 dynamics · reward 층 4개, DINO-WM의 예측기 블록 6개)을 보정한 균일 격자 위에서 k 비트로 양자화한다. 과제마다 사전등록한 규칙이 held-out episode에서 k를 고르고(주로 round-to-nearest, 즉 det가 20%p 이상 잃는 가장 큰 k), $k-1$, k, $k+1$을 시험한다. 질문은 두 가지다. det는 왜 1-step 오차가 말해 주는 것보다 계획을 더 망가뜨리는가? 반올림만 바꾸면 이를 고칠 수 있는가?

B. 새로운 점

(1) 이용의 직접 측정. 계획기 이용 지수(OEI)는 실행된 계획의 모델 비용 오차에서 첫 반복 무작위 후보의 오차를 뺀 값이다. 이 값은 선택 항과 이동 항으로 정확히 나뉜다. (2) *2*축 대조: 항목별 오차 분포는 같고, 후보 간 공유 여부와 반복 간 지속 여부만 다른 확률적 변형들을 비교한다. (3) 같은 비트 수에서 학습 없이 쓰는 처방(sh-iter). 저비트 월드모델이나 VLA 추론에 dither나 확률적 반올림을 쓴 선행연구는 찾지 못했다. 가장 가까운 연구 [5]는 후보 공통 오차와 행동 상대 오차를 oracle 수리로 나누지만, 반복 축, 압축 오차, 배치 가능한 처방이 없다. 처방의 원리인 optimizer's curse [6], 공통 난수, 확률적 반올림 [7]은 고전적이다. 새로운 것은 이를 압축된 월드모델에 적용한 것, 두 축을 분리한 것, 효과의 크기다. (4) 내부 사전등록: 가설, 문턱, 코드를 단계마다 시각을 기록한 문서로 미리 고정했고, 성립하지 않은 가설도 보고한다(표 1).

C. 알고리즘

반올림 변형. 격자 간격이 Δ일 때 det는 x를 $\Delta\,\mathrm{round}(x/\Delta)$로, dither는 $u\sim U[0,1)$로 $\Delta\lfloor x/\Delta+u\rfloor$로 바꾼다. dither는 편향이 없다. 확률적 변형들은 u를 뽑는 방식만 다르다. 후보마다 따로 뽑거나(ind), 모든 후보가 공유하고 forward 호출마다 새로 뽑아 계획기 반복마다 새롭게 하거나(sh-iter, 처방), 공유하되 한 제어 step(sh-step) 또는 한 episode(sh-ep) 동안 고정한다(open-loop CEM에서는 둘이 같다). 나머지 계획기 설정은 공식값이다(MPPI: elite 64; CEM: top 30, Wall · PointMaze는 반복 10회). **이용.** 후보 a의 비양자화 모델 대비 비용 오차를 $e(a)$라 하면 $\mathrm{OEI}=e(a_{\mathrm{exec}})-\bar{e}_{\mathrm{first}}=$ 선택 + 이동이다. 이동은 모집단 평균 오차가 첫 반복에서 마지막 반복까지 바뀐 양이다. 이동이 음수이면 계획기가 오차가 유리한 후보

쪽으로 움직였다는 뜻이다. **이론.** 새로 뽑는 무편향 잡음의 이동 기대값은 0이다. 반면 지속되는 오차장은 모집단을 평활한 모델 비용의 최소점으로 끌고 간다(표본평균근사 편향). 유도한 선택·이동 항은 MPPI·CEM 모의 92만 2천 회와 맞았다(맞춘 기울기 0.92–1.05).

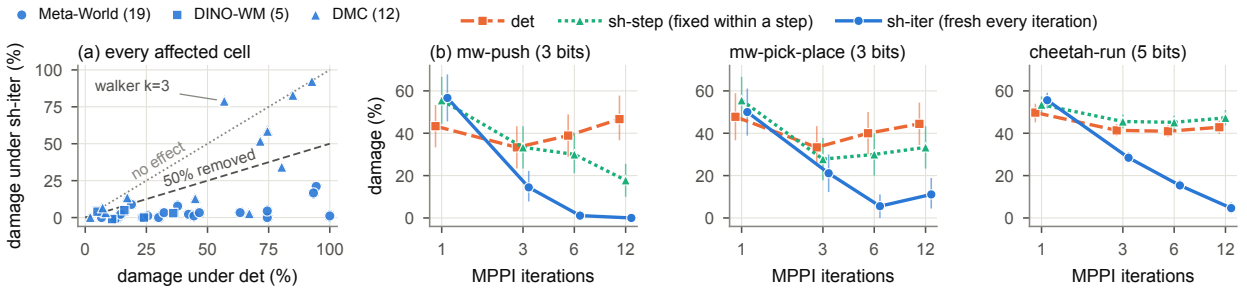


Fig. 1. (a) 모든 손상 칸에서 det 손상 대비 sh-iter 손상(성공률 하락, DMC는 상대 return 하락). 파선 아래는 sh-iter가 손상의 절반 이상을 없앤 칸이다. (b) MPPI 반복 수에 따른 손상(TD-MPC2, 짝 90 episode, 95% CI).

D. 실험

설정. TD-MPC2: 공식 5M checkpoint(seed 3개), Meta-World 8과제(성공률)와 DMC 4과제(return), 과제–비트 칸 36개, 변형마다 짝 90 episode. DINO-WM: 공식 PushT·Wall·PointMaze 모델, 9칸, 짝 100 episode. 모든 변형은 비양자화 기준선과 짝을 이루고(같은 seed와 계획기 잡음), 손상 D는 기준선 대비 하락이다(DMC는 상대 return). det 하락은 과제별 Holm 보정(짝 bootstrap, 95%)을 통과하면 실재한다고 보고, 그런 칸을 손상 칸이라 부른다(TD-MPC2 31칸, DINO-WM 5칸). **현상과 처방**(그림 1a). det는 성공률을 최대 100%p 떨어뜨린다(mw-button-press, 2비트). 이 손상 칸 36개 중 29개에서 det의 1-step 오차는 sh-iter보다 크지 않다(mw-pick-place 3비트: 0.22 대 0.39인데, 하락은 37.8%p 대 7.8%p). sh-iter는 Meta-World 손상 칸 19개 모두에서 손상의 절반 이상(중앙값 95%)을, DINO-WM 5칸 중 4칸에서 절반 이상을 없애고, Meta-World와 DINO-WM의 손상 칸 어디에서도 det보다 나쁘지 않다. **기전**(그림 1b). det에서는 기전 과제 네 개 모두에서(각 과제의 1차 비트 수) 모집단 평균 오차가 유리한 쪽으로 이동한다. sh-iter는 그 이동의 24% 이하만 남기고, TD-MPC2의 지속 dither는 70–130%를 남긴다. dither의 이득은 반복이 있어야 생긴다. 반복이 1회면 sh-iter도 det보다 낫지 않지만, 반복 12회에서는 sh-iter 손상이 0–11%이고 det는 43–47%에 머문다. elite 수를 고정하면 후보 수가 늘수록 이용과 손상이 함께 커지고(4과제 중 3과제), 고정 dither의 손상은 독립 offset 수(표 크기)가 커질수록 줄어든다(6과제 중 5과제). **DMC.** det의 유리한 오차 가운데 반복 사이에 지속되는 몫(지속 몫, 이동을 OEI로 나눈 값)은 DMC에서 0.33–0.52로 Meta-World(0.54–0.73)보다 작다. TD-MPC2 12과제 전체에서 이 몫은 sh-iter의 효과를 예측했다(Spearman 0.83, 1단계 뒤에 정하고 새 seed로 돌린 검정). DMC에서 sh-iter는 12칸 중 5칸에서만 손상의 절반 이상을 없애고, walker 3비트에서는 오히려 해롭다(return 손실 78.9% 대 56.9%).

가설과 사전등록 검정	결과
H1: 어떤 손상 칸에서 det의 1-step 오차 $\leq$ sh-iter	두 계열 모두 성립
H3a: 손상 칸의 75% 이상에서 sh-iter가 손상의 50% 이상 제거, 5%p 넘게 나쁜 칸 없음	Meta-World 19/19, DINO-WM 4/5; DMC 불성립
DMC 설명(1단계 뒤 추가): 지속 몫과 손상 제거율의 Spearman ≥ 0.5	성립: 12과제에서 0.83
H2a′(1단계 뒤 추가): det 이동 < 0, 이동 비 sh-iter/det < 0.5	성립: 4/4과제(비 $\leq$0.24)
H2c: 후보 수와 $\lvert\mathrm{OEI}_{\mathrm{det}}\rvert$, D_{det}의 Spearman ≥ 0.8	성립: 3/4과제
H4a: 표 크기와 고정 dither 손상의 Spearman ≤ -0.8	성립: 5/6과제(셋은 정확히 -0.8)
H3b: 최선 PTQ 위에서 3–4비트 칸 과반에서 sh-iter가 det보다 나음	TD-MPC2 성립(10/19); DINO-WM 불성립(1/3)
H5: dither 지연 오버헤드 $\leq$10%; Pareto 지배 설정 하나 이상	약하게 성립(최대 6.9%); fp32보다 빠르지 않음
H2a, H2b(원래 OEI 검정); H4b(near-tie 밀도와 공유 이득)	불성립(주장을 좁힘)

Table 1. 사전등록 가설과 결과. 기전 과제: mw-push, mw-pick-place, cheetah-run, PushT.

참고문헌. [1] N. Hansen, H. Su, X. Wang, TD-MPC2, ICLR, 2024. [2] G. Zhou et al., DINO-WM, arXiv:2411.04983, 2024. [3] Z. Fu et al., An empirical study of world model quantization, arXiv:2602.02110, 2026. [4] J. Xu et al., Predict before you deploy (PreDE), arXiv:2609.19441, 2026. [5] R. Min et al., When low prediction error misleads planning, arXiv:2610.05550, 2026. [6] J. E. Smith, R. L. Winkler, The optimizer's curse, Management Science, 2006. [7] S. Gupta et al., Deep learning with limited numerical precision, ICML, 2015.